

1. Markowitz의 평균 분산 모델에 따르면 k 개의 자산으로 구성된 포트폴리오에서 주어진 기대수익률에 대해 분산이 가장 작아지게 하는 각 자산 별 투자비중은 아래와 같이 도출할 수 있다.

① X_1, \dots, X_k 은 각 자산 별 수익률을 나타내는 유한한 분산 값을 가지는 확률변수로, X_1, \dots, X_k 의 공분산행렬을 $Q_{k \times k}$, 기대값 벡터는 $r_{k \times 1} = (r_1, \dots, r_k) = (E[X_1], \dots, E[X_k])$ 라고 하자.

② 각 자산 별 투자비중을 $w_{k \times 1} = (w_1, \dots, w_k)$ (단, $\vec{1}^T w = \sum w_i = 1$, $\vec{1}_{k \times 1} = (1, 1, \dots, 1)$)로 하는 포트폴리오 P 를 가정할 때, 포트폴리오 P 의 기대수익률은 $\mu_p = r^T w = \sum w_i r_i$, 분산은 $\sigma_p^2 = w^T Q w$ 가 된다.

③ 이 경우 다음을 만족하는 w 를 찾는 최적화 문제를 고려하자.

$$\min\{w^T Q w \mid w \in \mathcal{R}^k, \quad \vec{1}^T w = 1, \quad r^T w = \mu_p\}$$

즉 포트폴리오의 기대수익률 μ_p 이 원하는 수준에서 주어진 상태에서 포트폴리오의 분산 $w^T Q w$ 를 최소로 하기 위해 필요한 각 자산 별 가중치 $w = (w_1, \dots, w_k)$ 를 찾는 문제이다.

④ 이는 선형제약식을 가진 2차 함수에 대한 최적화 문제로, 라그랑지 이론에 따르면 아래와 같은 선형방정식계를 이용하여 풀 수 있다.

$$\begin{bmatrix} Q & \vec{1} & r \\ \vec{1}^T & 0 & 0 \\ r^T & 0 & 0 \end{bmatrix} \begin{bmatrix} w \\ \lambda_1 \\ \lambda_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ \mu_p \end{bmatrix}$$

(1) 이상의 내용을 수행하기 위한 파이썬 함수 MVportfolio를 작성하여라. 함수의 인자는 k 개의 자산 별 가격을 m 일 동안 일별로 수집한 $m \times k$ 의 데이터프레임 asset과, 원하는 포트폴리오 기대수익률 (μ_p)인 mu_p이고, 함수를 실행한 결과 k 개의 자산별 가중치 $w = (w_1, \dots, w_k)$ 와 포트폴리오 분산 σ_p^2 값이 반환되어야 한다. 단, 각 자산 별 일별 수익률은 $\log(\text{해당일가격}/\text{전일가격})$ 으로 구하여라.

(2) 5개의 자산 가격을 일별로 수집한 'it.csv'의 자료에 (1)에서 작성한 MVportfolio 함수를 적용하여, μ_p 가 -0.001에서 0.0010사이의 값을 가질 때 최적의 투자비중으로 계산된 분산 σ_p^2 를 도출한 뒤, 이를 이용하여 효율적인 투자선 (가로축은 σ_p^2 , 세로축은 μ_p 인 선그림)을 도출하여라.

2. 다음은 12개월 모멘텀을 이용하여 10개의 종목을 선택하는 문제이다.

- (1) 'price.csv' 파일을 불러온 뒤, 'date' 열이 DatetimeIndex 자료형이 되도록 변경한 뒤, 이를 Index로 하는 pd.DataFrame 객체 price를 생성하여라.
- (2) price에서 2019년도에 해당하는 자료만 선택하여 price_sub 로 저장하여라.
- (3) price_sub에서 각 종목 별(열 별)로 일별 수익률($=1 + \text{변화율}$)에 대한 누적곱으로 누적 수익률을 구한 뒤 cum_ret라는 pd.Series 객체로 저장하여라.
- (4) cum_ret에서 누적수익률이 높은 순서로 10개 종목을 출력한 뒤, 가장 누적수익률이 높은 종목에 대한 2019년 price의 시계열 그림을 출력하여라.
- (5) price_sub에서 각 종목 별(열 별)로 일별 변화율에 대한 표준편차에 252의 제곱근을 곱하여, 각 종목 별 연율화 변동성을 구한 뒤 이를 std라는 pd.Series 객체로 저장하여라.
- (6) std에서 std가 0인 경우와 NaN인 경우를 제외하여라.
- (7) 종목 별 cum_ret와 std의 비율로 정의되는 위험조정 수익률 노게 ($= \text{cum_ret} / \text{std}$)를 pd.Series 객체로 저장하여라.
- (8) 위험조정 수익률 shrp에 NaN이 포함된 경우는 이를 shrp의 최소값으로 대체하여라.
- (9) 위험조정 수익률 shrp의 값이 큰 순서대로 10개 종목을 선택하여라.
- (10) 선택된 10개 종목을 index로 하고, 10개 종목에 대한 누적수익률(cum_ret 값), 변동성(std 값), 위험조정수익률(shrp 값)을 column으로 하는 pd.DataFrame 객체 final_result를 생성한 뒤 출력하여라.

3. 유러피안 콜 옵션 가격 몬테카를로 시뮬레이션 다음 ECallSimul_1은 유러피안 콜 옵션 가격을 몬테카를로 시뮬레이션으로 도출하기 위한 함수를 작성한 것이다. (산출식, 변수명 등은 ch3 강의에서 다룬 내용과 동일함)

```
def ECallSimul_1(S0, K, T, r, sigma, M, l=250000):
    import math
    import random
    S = []
    dt = T/M
    for i in range(l):
        path = []
        for t in range (M+1):
            if t == 0 :
                path.append(S0)
            else:
                z=random.gauss(0, 1.)
                St = path[t-1] * math.exp( (r-0.5*sigma**2)*dt + sigma * math.sqrt(dt)*z )
                path.append(St)
        S.append(path)
    sum_val = 0.0
    for path in S:
        sum_val += max(path[-1]-K, 0)
    C0 = math.exp(-r*T)*sum_val/l
    return ( round(C0, 3) )
```

- (1) ECallSimul_1 함수의 body에서 가능한 모든 부분을 Numpy의 기능을 활용하는 것으로 수정한 뒤 ECallSimul_2라는 함수로 저장하여야.
- (2) S0=100., K=105., T=1., r=0.05, sigma=0.2, M=50, l=250000인 경우에 대하여 두 함수 ECallSimul_1과 ECallSimul_2의 결과가 유사한 지 확인해 보고, 두 함수의 연산시간을 비교하여라. (※ Jupyter Notebook에서 %time이라는 매직 명령어 뒤에 실행하고자 하는 코드를 작성하면 그 코드를 실행하는데 소요된 CPU time을 출력할 수 있음.)

<결과 예시>

```
In [3]: %time ECallSimul_1(S0=100., K=105., T=1., r=0.05, sigma=0.2, M=50, l=250000)
```

```
Wall time: 12.9 s
```

```
Out[3]: 8.01
```

```
In [4]: %time ECallSimul_2(S0=100., K=105., T=1., r=0.05, sigma=0.2, M=50, l=250000)
```

```
Wall time: 747 ms
```

```
Out[4]: 7.987
```

→ ECallSimul_1의 경우 12.9 seconds, ECallSimul_2의 경우 747 milliseconds로 Numpy를 활용한 경우 연산속도가 대략 17배 빠름을 확인할 수 있음.

